



RAG

FOUNDATIONS

Instrutor(a): Lucas Mendes



MERGULHE EM TECNOLOGIA_





LUCAS MENDES

CTO DO GRUPO EBG - PROFESSOR DE IA

 www.linkedin.com/in/lucas-mendes-araujo

 lucas.mendes@grupoebg.com.br

SOBRE MIM


TRANSFORMANDO dados
em decisões inteligentes
com **IA** e **AUTOMAÇÃO**.

ENSINANDO como a **IA**
pode **TRANSFORMAR**
negócios e carreiras.


FUNDAMENTOS DE LLMS E MOTIVAÇÃO PARA O RAG




LARGE LANGUAGE MODELS (LLMs)



<https://arxiv.org/abs/1706.03762>





FINE-TUNING VS RAG

FINE-TUNING

Em vez de “ensinar tudo do zero”,
você especializa o modelo.



RAG

Em vez de ensinar o modelo, você
conecta o modelo ao conhecimento.



FINE-TUNING

Como o modelo responde

RAG


Com base em quê o modelo responde

Cenário / Necessidade	Fine-tuning	RAG
Padronizar tom, estilo e formato	✓	✗
Respostas sempre no mesmo padrão	✓	✗
Linguagem institucional rígida	✓	✗
Conhecimento atualizado com frequência	✗	✓
Documentos internos (PDF, contratos, políticas)	✗	✓
Necessidade de explicação baseada em fonte	✗	✓


ARQUITETURA GERAL DO RAG

RAG (RETRIEVAL AUGMENTED GENERATION)

Permite uma busca de informações relevantes em bases externas (documentos, etc) antes de gerar a resposta final.





RAG (RETRIEVAL AUGMENTED GENERATION)




PROMPT TRADICIONAL


QUAIS SÃO AS REGRAS DE
RETIRADA DA CESTAS DE NATAL?



RESPOSTA



RAG (RETRIEVAL AUGMENTED GENERATION)



EMBEDDINGS E SIMILARIDADE

SEMÂNTICA

O QUE SÃO EMBEDDINGS

Embeddings são representações numéricas de textos (ou imagens, áudios, etc.) em forma de vetores.

Em vez de o modelo “ver palavras”, ele passa a ver números que carregam significado.

Frase	Embedding
contrato de trabalho	[0.12, -0.87, 0.44, ...]
acordo empregatício	[0.11, -0.85, 0.46, ...]
demissão sem justa causa	[0.21, -0.66, 0.39, ...]
rescisão contratual imotivada	[0.22, -0.64, 0.41, ...]
banco de dados	[0.88, -0.12, 0.77, ...]
sentar no banco da praça	[-0.42, 0.91, -0.33, ...]
política de cancelamento de plano	[0.14, -0.73, 0.29, ...]


BUSCA SEMÂNTICA




Busca semântica é a técnica que permite encontrar informações pelo significado, e não apenas pela correspondência exata de palavras.

Em vez de procurar termos iguais no texto, o sistema converte a pergunta e os documentos em embeddings e compara a proximidade entre vetores no espaço vetorial.

Isso faz com que conteúdos com ideias semelhantes, mesmo usando palavras diferentes, sejam recuperados como relevantes.



RAG (RETRIEVAL AUGMENTED GENERATION)




MÉTRICAS DE SIMILARIDADE SEMÂNTICA

O QUE SIGNIFICA MEDIR SIMILARIDADE

Medir similaridade é dizer o quão próximos dois textos são em significado, usando seus vetores de embeddings.

Quanto mais próximos, mais semanticamente semelhantes.



O QUE SIGNIFICA MEDIR SIMILARIDADE

Similaridade de Cosseno

Distância Euclidiana

Produto Escalar

Similaridade de Cosseno

O que mede:

Ângulo entre dois vetores [direção].

Frases

A: “contrato de trabalho”

B: “acordo empregatício”

Embeddings

- $A \rightarrow [0.12, -0.87, 0.44, \dots]$

- $B \rightarrow [0.11, -0.85, 0.46, \dots]$

Vetores apontam para a mesma direção
Tamanho pouco importa

0.98 [muito semelhante]

Mesmo com palavras diferentes, os textos falam da mesma coisa.

EMBEDDINGS OPEN SOURCE VS PROPRIETÁRIOS

EMBEDDINGS PROPRIETÁRIOS

São embeddings oferecidos por empresas, via API, com modelos fechados e otimizados, sem acesso aos pesos internos.

Dados saem do ambiente

Empresa	Modelo de Embedding	Página oficial
OpenAI	text-embedding-3-small / text-embedding-3-large	https://platform.openai.com/docs/guides/embeddings
Google (Gemini / Vertex AI)	Gemini Embeddings	https://cloud.google.com/vertex-ai/docs/generative-ai/embeddings
Microsoft (Azure OpenAI)	OpenAI Embeddings (Azure)	https://learn.microsoft.com/azure/ai-services/openai/concepts/embeddings
Cohere	embed-english-v3.0 / embed-multilingual-v3.0	https://docs.cohere.com/docs/embeddings
Amazon (Bedrock)	Titan Embeddings	https://docs.aws.amazon.com/bedrock/latest/userguide/titan-embeddings.html


EMBEDDINGS OPEN SOURCE

São modelos abertos, que podem ser executados localmente ou na nuvem, com controle total sobre dados e infraestrutura.

Ideal para dados sensíveis

Empresa	Modelo de Embedding	Página oficial
Sentence-Transformers	all-MiniLM-L6-v2	https://www.sbert.net/docs/pretrained_models.html
Sentence-Transformers	all-mpnet-base-v2	https://www.sbert.net/docs/pretrained_models.html
Meta	LLaMA Embeddings	https://ai.meta.com/llama/
Mistral AI	Mistral Embeddings	https://docs.mistral.ai/capabilities/embeddings/
Alibaba (Qwen)	Qwen Embeddings	https://github.com/QwenLM/Qwen
Hugging Face	Modelos de Embeddings (Hub)	https://huggingface.co/models?pipeline_tag=sentence-similarity

POR QUE **CHUNKING** É ESSENCIAL




O QUE É CHUNKING

É o processo de dividir documentos longos em partes menores (chunks) antes de gerar embeddings.

Cada chunk deve representar uma unidade de significado, e não apenas um pedaço aleatório de texto.

Embeddings são gerados por chunk, não por documento completo.

Cada chunk vira um vetor



ESTRATÉGIAS DE CHUNKING

CHUNKING POR TAMANHO FIXO

Divide o texto a cada N caracteres, independentemente do sentido.

Texto Original:


Política de Cancelamento

O cliente pode solicitar o cancelamento do plano a qualquer momento...
[texto longo]

Chunks gerados:

Chunk 1: Política de Cancelamento O cliente pode solicitar o cancelamento do plano a qualquer momento desde que...

Chunk 2: ...sejam respeitados os prazos contratuais definidos na cláusula 4.2 do contrato...



ESTRATÉGIAS DE CHUNKING

CHUNKING POR SENTENÇAS

Divide o texto respeitando o final das frases.

Texto Original:


O cliente pode cancelar o plano. O cancelamento deve ser solicitado com antecedência mínima de 30 dias. Multas podem ser aplicadas.

Chunks gerados:

Chunk 1: O cliente pode cancelar o plano.

Chunk 2: O cancelamento deve ser solicitado com antecedência mínima de 30 dias.

Chunk 3: Multas podem ser aplicadas.



ESTRATÉGIAS DE CHUNKING

CHUNKING POR PARÁGRAFOS

Cada parágrafo vira um chunk (ou pequenos grupos de parágrafos).

Texto Original:

Parágrafo 1:

O cliente pode cancelar o plano a qualquer momento, desde que respeite as condições contratuais.

Parágrafo 2:

O prazo mínimo para solicitação de cancelamento é de 30 dias, contados a partir da data do pedido.

Texto Original:

Chunk 1: O cliente pode cancelar o plano a qualquer momento.....

Chunk 2: O prazo mínimo para solicitação de cancelamento é de



ESTRATÉGIAS DE CHUNKING

OVERLAPPING (SOBREPOSIÇÃO DE CHUNKS)

Parte do conteúdo é repetida entre chunks consecutivos.

Exemplo [500 tokens, overlap 100]


Chunk 1: tokens 1–500

Chunk 2: tokens 401–900


Chunks gerados:

Chunk 1: ... o cliente pode solicitar o cancelamento do plano a qualquer momento desde que...

Chunk 2: ... cancelar o plano a qualquer momento desde que respeite os prazos contratuais...



ENRIQUECIMENTO COM METADADOS



O QUE SÃO METADADOS

Metadados são informações adicionais associadas a um documento ou chunk que descrevem o contexto, mas não fazem parte do texto principal.

Em RAG, metadados não servem para gerar embeddings, eles servem para filtrar, organizar e direcionar a busca.



TIPOS DE METADADOS

Origem

Indica de qual documento ou sistema aquele chunk veio.

Seção

Identifica onde dentro do documento o texto está.

Categoria

Classifica o domínio do conteúdo.

O cliente pode solicitar o cancelamento do plano a qualquer momento, desde que respeite os prazos e condições estabelecidos no contrato vigente.

Metadados do chunk

```
{  
  "origem": "Manual_do_Cliente.pdf",  
  "secao": "Política de Cancelamento",  
  "categoria": "Jurídico"  
}
```

O QUE É UM VECTOR STORE

O QUE É UM VECTOR STORE


Um VectorStore (banco vetorial) é um sistema projetado para armazenar embeddings e permitir busca por similaridade semântica.

Em vez de responder:

- "Qual texto tem essa palavra?"

Ele responde:

- "Qual texto tem significado parecido com essa pergunta?"



BANCO RELACIONAL VS BANCO VETORIAL

Aspecto	Banco Relacional (SQL)	VectorStore
Tipo de busca	Exata / lógica	Similaridade
Comparação	Igualdade (=), LIKE	Distância vetorial
Dados	Estruturados	Não estruturados
Caso de uso	Transações, relatórios	Busca semântica




EMBEDDINGS

Vetores numéricos que representam o significado do texto.



METADADOS

Informações adicionais que dão contexto e explicam o conteúdo.



ÍNDICE VETORIAL


Estrutura otimizada para busca rápida



SIMILARIDADE

Define como medir a proximidade entre vetores semânticos.

RAG (RETRIEVAL AUGMENTED GENERATION)



VECTORSTORES NA PRÁTICA

FAISS

FAISS é uma biblioteca de busca por similaridade vetorial.
Ele não é um banco, é um motor de cálculo de vetores

É o núcleo de busca vetorial.
Mais focado para Notebook local

Exemplo prático

Um notebook Python que carrega 50 mil embeddings em memória
e faz busca semântica para validar qualidade do RAG.

CHROMA (CHROMADB)

ChromaDB é um VectorStore pronto para uso, focado em RAG com LLMs.

VectorStore completo

- Armazena embeddings
- Guarda textos
- Suporta metadados
- Persistência local

Exemplo prático

Um chatbot RAG lendo PDFs locais usando LangChain + ChromaDB em poucas linhas de código.

SUPABASE (POSTGRES + PGVECTOR)

Supabase é uma plataforma backend que permite usar PostgreSQL como VectorStore, via extensão pgvector.

VectorStore completo

- Banco relacional + vetores
- SQL + busca semântica
- Metadados estruturados
- Ambientes corporativos

Exemplo prático

- Contratos ficam em tabelas SQL
- Embeddings em colunas vetoriais
- Filtros por área, versão e permissão de usuário

RECUPERAÇÃO AVANÇADA

LIMITAÇÕES DA RECUPERAÇÃO

Pergunta → Embedding → VectorStore → Top-k documentos → LLM

Ranking puramente vetorial

- Baseado apenas na distância entre embeddings
- Não considera intenção fina da pergunta

Documentos semanticamente próximos, mas pouco úteis

- Texto parecido ≠ texto que responde bem
- Pode recuperar contexto genérico

Mistura de relevância

- Um documento muito relevante pode ficar em 4º ou 5º lugar
- O LLM recebe contexto subótimo

RERANKING

Reranking é uma etapa adicional que ocorre após a recuperação inicial.

Recupera-se um conjunto maior de candidatos (ex: top-20)
Aplica-se um modelo mais preciso para reordenar esses documentos
Seleciona-se o top-k final realmente relevante

Pergunta → Retriever (Top-20) → Reranker → Top-3 / Top-5 → LLM

Exemplo prático

Pergunta:
“Posso cancelar meu plano?”

Retriever Top-20

Segunda camada valida qual chunk é realmente mais relevante (Reranking)

Entrega contexto mais qualificado ao LLM

CAMINHOS DE EVOLUÇÃO DO RAG